Trabajo 3 - Nombre grupo: CofCof

Benjamín B.
20.165.296-0
benjamin.basauri@mail.udp.cl
kaggle user:benjamínb

Paolo E.
19.913.128-1
paolo.escobar@mail.udp.cl
kaggle user:PAOLO ANDRES ESCOBAR MUNOZ

Pedro O.
20.232.750-8
pedro.olivares1@mail.udp.cl
kaggle user: PEDRO OLIVARES1

Marcelo Y.
19.740.704-2
marcelo.araya1@mail.udp.cl
kaggle user: mrclynz

***Resumen*—En este informe se detalla el proceso de creación de una red neuronal convolucional para la identificación del diagnóstico de COVID-19, utilizando el conjunto de datos de registros de tos en audio denominado *CoughVid*.**

***Index Terms*—CNN, Audio, Image, Deep Learning.**

I. Introducción

Los avances en inteligencia artificial, especialmente en aprendizaje profundo y redes neuronales, han permitido mejoras notables en la detección y diagnóstico de enfermedades. Las redes neuronales convolucionales, en particular, han revolucionado el análisis y la identificación de patologías, proporcionando herramientas más precisas y eficientes para el sector de la salud. Este informe se centra en desarrollar un modelo de CNN que transforme audios de tos en imágenes de espectrogramas. Estos espectrogramas, que visualizan las frecuencias a lo largo del tiempo, permiten un análisis detallado y automatizado. Nuestro objetivo es utilizar estas imágenes para determinar, mediante características específicas capturadas en los espectrogramas, si las personas en los audios podrían estar afectadas por el COVID-19. Esta innovadora metodología no solo busca aumentar la precisión de los diagnósticos sino también agilizar el proceso de detección.

II. Redes neuronales

Una red neuronal artificial (ANN) es un modelo basado en la estructura y función de las redes neuronales biológicas presentes en los cerebros de los animales. El primero de estos modelos es el perceptrón creado por McCulloch y Pitts.

El perceptrón consiste en un modelo simple, que computa la suma ponderada de su vector de entrada y luego utiliza una función de activación para convertir este valor en una salida:

$$f(x) = \phi(\theta^T X + \theta_0) \tag{1}$$

Donde ϕ es la función de activación, X es el vector de entrada, θ es el vector de pesos y θ_0 corresponde al sesgo del modelo.

La mayor limitación de este modelo es que solo puede resolver problemas linealmente separables. El perceptrón no se puede utilizar para resolver problemas como XOR.

La introducción del algoritmo de retropropagación permite entrenar redes neuronales de varias capas. Gracias a este avance es posible generar modelos con representaciones internas más complejas.

III. Capas y Funciones de Activación

Las redes neuronales se organizan en capas, donde las neuronas de una capa solo están conectadas con neuronas de las capas adyacentes. Podemos considerar cada capa de la red neuronal como un nivel en el proceso de procesamiento de los datos.

La capa donde se recibe la información de entrada corresponde a la *input layer*, mientras que la capa que entrega la salida del modelo se denomina *output layer*. Todas las capas entre la capa de entrada y la capa de salida se denominan capas ocultas (*hidden layers*).

III-A. Capas Densas (Fully Connected Layers)

En una capa densa, o completamente conectada, cada neurona de una capa se encuentra conectada a todas las neuronas de la capa siguiente. Esta característica permite una interacción compleja de todas las componentes del vector de entrada. Esta capacidad hace que una red formada por capas densas puedan modelar cualquier función matemática con el número adecuado de neuronas y capas ocultas. [1], [2]

Una arquitectura basada en capas densamente conectadas (*DenseNet*) ofrece beneficios significativos como:

- Mitigación del desvanecimiento de gradientes.
- Mejora en la propagación y reutilización de características.

Estas ventajas hacen que las DenseNets sean efectivas en tareas complejas como regresiones no lineales y procesamiento de imágenes[3], [4]. También se ha hecho uso de estas redes para resolver problemas como la clasificación de tumores cerebrales, demostrando su utilidad en aplicaciones prácticas[5].

III-B. Función de Activación ReLU (Rectified Linear Unit)

La función Rectified Linear Unit está definida como:

$$ReLU(x) = \begin{cases} 0 & x < 0, \\ x & x \geq 0 \end{cases} \tag{2}$$

La función de activación ReLU se introduce para resolver el problema del gradiente desvaneciente con las funciones de activación saturadas como *sigmoide* y *tanh*, las cuales tienen un dominio acotado que genera gradientes pequeños. Esta característica de la función ReLU facilita el entrenamiento de modelos más complejos, siendo crucial para las arquitecturas de *deep learning*[6], [7], [8].

La capacidad de la función de ReLU de mitigar el desvanecimiento de gradiente permite que las redes neuronales se entrenen más rápido y en algunos casos, mejora la convergencia del modelo[9], [10]. Además, al ser una función simple no requiere de una gran capacidad de computo, lo que la hace ideal para aplicaciones de procesamiento en tiempo real[11].

III-C. Función de Activación sigmoidal

$$\sigma(x) = \frac{1}{1 + e^{-x}} \tag{3}$$

La función sigmoidal, también conocida como función logística, es una función matemática que tiene una característica forma de ”S”(sigmoide). Es ampliamente utilizada en diversos campos, especialmente en la ciencia de datos y aprendizaje automático, debido a sus buenas propiedades para modelar comportamientos que describen crecimiento en presencia de restricciones o saturación, en el contexto actual de clasificación de espectrogramas se utiliza para definir dividir en 0 y 1 la existencia de covid o no en dicho espectrograma

IV. Espectrogramas

Los espectrogramas son representaciones gráficas que muestran cómo varían las intensidades de las frecuencias en una señal de audio a lo largo del tiempo Se generan mediante la transformación de Fourier que descompone la señal de audio en sus componentes frecuenciales Esta herramienta es esencial en diversos campos como la música la lingüística y la ingeniería de sonido porque permite visualizar y analizar características del sonido que no son fácilmente detectables solo por la escucha.

IV-1. Visualización de Frecuencias: Un espectrograma desglosa una señal de audio en un eje de tiempo (horizontal) y un eje de frecuencia (vertical) con colores que representan la intensidad de cada frecuencia en puntos específicos del tiempo Esta capacidad de desglose permite

Identificar Instrumentos y Fuentes Sonoras Cada instrumento musical tiene un patrón característico de frecuencias que puede ser identificado en el espectrograma Por ejemplo un violín puede mostrar frecuencias más altas y un patrón armónico distinto al de una guitarra

Separación de Fuentes En una grabación con múltiples fuentes sonoras un espectrograma puede ayudar a distinguir entre estas fuentes facilitando procesos como la mezcla de música o el aislamiento de voces en una grabación

IV-2. Detección de Patrones: Los patrones frecuenciales visibles en los espectrogramas son claves para diversas aplicaciones

Reconocimiento de Voz y Música Algoritmos de aprendizaje automático pueden ser entrenados para reconocer patrones específicos en los espectrogramas que correspondan a palabras frases o incluso estilos musicales

Análisis Rítmico En música los patrones de frecuencia pueden mostrar el ritmo y la cadencia elementos cruciales para el análisis musical y la generación automática de música

Diagnóstico Automatizado En la tecnología de asistencia y salud la detección de patrones en el habla puede ayudar a diagnosticar condiciones como la disartria o el parkinsonismo donde el patrón de habla se altera notablemente

IV-3. Análisis Temporal: El eje de tiempo en un espectrograma permite observar cómo las frecuencias se modifican a lo largo del tiempo lo cual es fundamental para

Segmentación de Audio Identificar cuándo comienza y termina un sonido específico dentro de una secuencia más larga útil en la edición de audio y en sistemas de respuesta automática

Dinámica de los Sonidos Observar cómo la intensidad y la presencia de ciertas frecuencias cambian puede indicar cambios en la dinámica de un instrumento musical la emoción en una voz o la presencia de eventos sonoros específicos como aplausos o disparos

En conjunto el análisis mediante espectrogramas abre una ventana detallada al estudio de las propiedades del sonido permitiendo no solo una mejor comprensión y manipulación de las señales de audio sino también el desarrollo de tecnologías avanzadas de procesamiento y análisis sonoro

V. CNN vs DNN

V-1. Redes Neuronales Densas (DNN): Las Redes Neuronales Densas, o DNN, son un tipo de red neuronal en el que cada neurona de una capa está conectada a todas las neuronas de la capa siguiente. Estas redes son conocidas por su estructura simple y son utilizadas comúnmente en problemas de clasificación y regresión que no requieren el procesamiento de la estructura espacial de los datos, como la predicción de precios de acciones o el análisis de sentimientos. Una de las principales ventajas de las DNN es su efectividad en datos tabulares o no estructurados. Sin embargo, pueden ser ineficientes para trabajar con datos de alta dimensión como imágenes, debido a que no explotan las relaciones espaciales o temporales en los datos.

V-2. Redes Neuronales Convolucionales (CNN): Por otro lado, las Redes Neuronales Convolucionales, o CNN, están diseñadas específicamente para procesar datos que tienen una estructura de rejilla, como imágenes. Utilizan una técnica conocida como convolución para capturar patrones espaciales en los datos a través de filtros. Esto les permite detectar características como bordes y texturas, lo que es fundamental en aplicaciones como el análisis de imágenes y videos, el reconocimiento facial y los sistemas de visión para vehículos autónomos. Las CNN son más complejas de diseñar y entrenar que las DNN, pero su capacidad para manejar eficientemente datos visuales las hace indispensables en campos relacionados con la visión por computadora.

V-3. ¿Cuándo y por qué usar cada una?: La elección entre usar una DNN o una CNN depende en gran medida del tipo de datos y del problema específico que se está abordando. Las DNN son adecuadas para datos que son ricos en información pero que no están organizados en forma de rejilla. En contraste, las CNN son la mejor opción para problemas que pueden beneficiarse de la captura automática y eficiente de características locales en datos estructurados espacialmente, como las imágenes.

VI. Metodología y Experimentos

VI-1. Procesamiento de los datos:

- **Creación de espectrogramas** Se crean espectrogramas de los audios, con el objetivo de utilizarlos en el entrenamiento de la red CNN más adelante.

VI-2. Desarrollo de experimentos:

- **Capa convolucional:** Se utilizan 3 capas de convolución, con activación ReLU, para entrenar utilizando los espectrogramas.
- **Capas ReLU:** Como función de activación se decidió utilizar ReLU por su gran rendimiento (tanto en profundidad como en velocidad). En total se utilizan cuatro capas ReLU para mejorar su capacidad de aprender.
- **Capa de max-pooling:** Después de cada capa de convolución se utiliza una capa de max-pooling para reducir la cantidad de datos antes de avanzar a la siguiente capa
- **Capas de aplanamiento:** Para reducir la dimensionalidad de los datos se utiliza una capa de aplanamiento (*flatten layer*), dejando los datos listos para realizar el entrenamiento. Esta se aplica después de la ultima capa de max-pooling.
- **Capas densas:** Dentro del modelo se hace uso de capas densas para conectar las capas con el objetivo de cambiar las dimensiones con las que entran los vectores. Se utilizan dos de estas capas, la primera con activación ReLU, y la segunda con activación sigmoide.
- **Dropout:** Después de la primera capa densa, se utiliza *dropout* con el objetivo de evitar *overfitting*.
- **Capa sigmoide:** Para clasificar los resultados como verdadero o falso, la ultima capa densa conectara a una función de activación sigmoide.
- **Perdida de entropía cruzada:** Debido a que se tiene un problema de clasificación, se utiliza la perdida de entropía cruzada como función de perdida.
- **Inicialización:** Se elige utilizar el método de inicialización de He debido a que este considera particularmente las características de la función ReLU, con el fin de evitar el problema de vanishing gradients o exploding gradients[12].
- **Parámetros:** Los parámetros en uso fueron escogidos por dar los mejores resultados después de una serie de intentos con diferentes valores.
- **Iteraciones:** Se realizan 36 iteraciones en el entrenamiento con una tasa de aprendizaje de 0.001, debido a que esto da los mejores resultados después de realizar prueba y error.

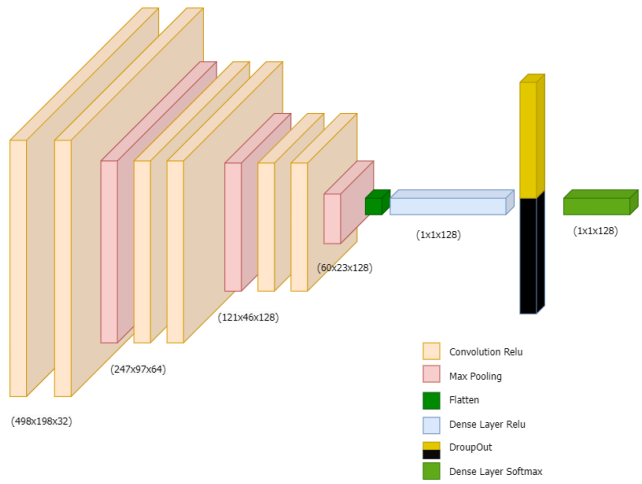

Figura 1. Arquitectura del modelo.

VII. Resultados

Se exponen los resultados obtenidos:

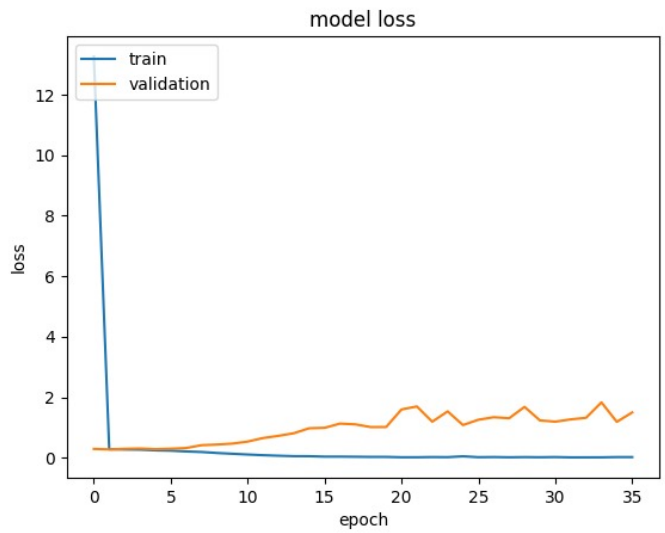

Figura 2. Gráfico de precisión (validation accuaracy) por cada pliegue (fold) del proceso de validación cruzada K-Fold.

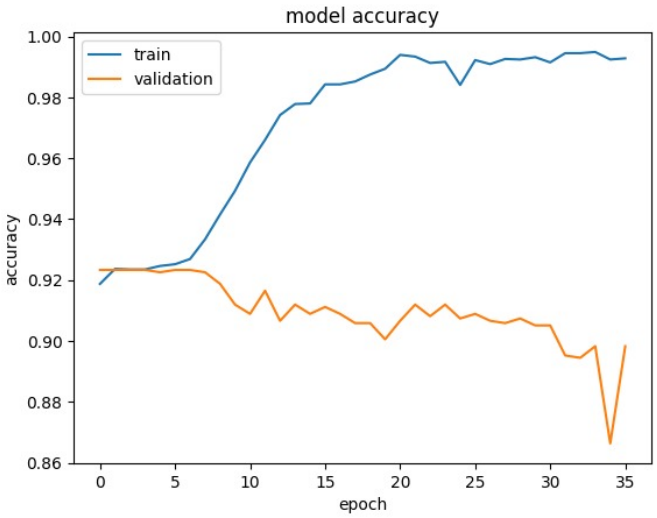

Figura 3. Gráfico de perdidas (loss) vs iteraciones (epochs) para los 5 folds.

VIII. Conclusiones

Las Redes Neuronales Convolucionales (CNN) son fundamentales en el procesamiento de datos con estructura de rejilla, como imágenes y espectrogramas, gracias a su operación principal, la convolución. Esta operación implica filtros que se desplazan sobre la imagen de entrada para generar mapas de características que capturan detalles como bordes y texturas. Posteriormente, las operaciones de pooling reducen la dimensionalidad de estos mapas, lo que optimiza el procesamiento y aumenta la robustez ante variaciones de posición de las características detectadas. Las funciones de activación, como la ReLU, se aplican después para introducir no linealidades, permitiendo a la red aprender representaciones más complejas. Las CNN son especialmente eficientes para analizar imágenes debido a su habilidad para aprovechar la correlación espacial entre píxeles y requieren menos parámetros que las redes densas, lo que minimiza el riesgo de sobreajuste y mejora la eficiencia computacional. Esta capacidad para capturar características locales y reconocer patrones de manera eficiente las hace ideales para tareas como el reconocimiento de objetos y la clasificación de imágenes. En el diagnóstico de COVID-19 mediante el análisis de espectrogramas de audios de tos, las CNN demuestran su valor al identificar patrones asociados con la enfermedad en estas representaciones visuales de las señales de audio, lo que es crucial para diagnósticos rápidos y precisos. En resumen, las CNN no solo son poderosas en visión por computadora, sino que su aplicación en la salud para diagnósticos y manejo de enfermedades como el COVID-19 subraya su impacto transformador en la medicina moderna.

Referencias

[1] F. M. et all, “An efficient optimization technique for training deep neural networks,” 2023.
[2] G. D. C. et all, “Exploring neural network hidden layer activity using vector fields,” 2020.
[3] W. Z. et all, “Dense convolutional neural network for identification of raman spectra,” 2023.
[4] C. J. et all, “Densely connected neural networks for nonlinear regression,” 2022.
[5] O. Özkaraca et all, “Multiple brain tumor classification with dense cnn architecture using brain mri images,” 2023.
[6] Z. B. et all, “Joint gravity and magnetic inversion using cnns’ deep learning,” 2024.
[7] A. P. et all, “Sinlu: Sinu-sigmoidal linear unit,” 2022.
[8] G. M. et all, “Nipuna: A novel optimizer activation function for deep neural networks,” 2023.
[9] D. C. et all, “Deep residual learning for nonlinear regression,” 2020.
[10] J. P. et all, “Embedding soft thresholding function into deep learning models for noisy radar emitter signal recognition,” 2022.
[11] K. S. et all, “Improved u-net: Fully convolutional network model for skin-lesion segmentation,” 2020.
[12] K. He, X. Zhang, S. Ren, and J. Sun, “Delving deep into rectifiers: Surpassing human-level performance on imagenet classification,” 2015.